Apache ZooKeeper

Отказоустойчивый ансамбль и восстановление расчёта

Практическая работа

Студентка	Группа	ИСУ
Вита-Виктория Гиалтсо-Мижа	j3313	466703

Вариант 7 · разработчик на Go

ZooKeeper 3.9.6 · Java 17 · таймаут сессии 10 секунд

1. Ансамбль и кворум

Три процесса ZooKeeper 3.9.6 запущены на одной машине. У каждого собственные dataDir и myid. В конфигурациях совпадает список server.1–server.3; клиентские порты 2181–2183, порты кворума и выборов выделены отдельно для каждого процесса.

Проверки состояния

Сценарий	Наблюдение
Все три процесса	2 followers и 1 leader
Остановлен server 1	Два сервера сохранили кворум; запись через клиента успешна
Остановлены server 1 и 2	server 3 остался без большинства; клиентская операция не прошла
После перезапуска	Все три сервера вернулись в роли leader/follower
Эфемерный znode	Узел существовал в сессии; после закрытия сессии exists=false

Временные порты на localhost нужны потому, что три экземпляра работают на одной машине. В реальном ансамбле каждому серверу назначается отдельный узел сети, и тогда порты кворума можно повторять.

2. Координаторы и чекпоинт

Два процесса Python используют KazooClient с session timeout 10 секунд. Они создают ephemeral sequential znodes под /coordinators. Координатор с наименьшим порядковым номером становится лидером; второй ждёт удаления предыдущего узла. Смена эпохи хранится в /control/epoch.

Расчёт и восстановление

Набор состоит из 124 вакансий Go. Каждая вакансия обрабатывается один раз: навыки нормализуются и из них формируются пары. После каждого чанка частичные счётчики атомарно сохраняются в checkpoint.json. Лидера приостанавливали на 40 секунд после завершения первых чанков. ZooKeeper удалил его ephemeral znode после истечения сессии, резервный координатор стал лидером и обработал только отсутствующие чанки.

Время смены лидера

Режим	Смена лидера, с	Версия указателя	Пик RSS A / B, MiB	Сверка с ДЗ №3
Без эпохи	10.413	2	24.14 / 25.70	Да
С эпохой	10.938	1	23.59 / 24.70	Да

Время измерено локальными монотонными часами от отправки SIGSTOP лидеру до записи BECAME_LEADER в журнал резервного процесса. Это включает обнаружение истечения ZooKeeper-сессии, поэтому измерение показывает поведение всего failover-сценария, а не только внутреннюю фазу голосования.

3. Проверка результата и эпохи

Эталон — полный файл пар из расчёта ДЗ № 3 для варианта Go. Резервный координатор восстановил те же пары после чекпоинта. Пары сравниваются по ключам и числам, а не только по общей сумме.

Контроль	ДЗ № 3	ZooKeeper ДЗ	Результат
Различных пар	1 008	1 008	Совпало
Вхождений пар	2 382	2 382	Совпало

Два сценария публикации

Без защиты получатель принял запись координатора B, а затем позднюю запись координатора A со старой эпохой: указатель результата перешёл на версию 2. Это демонстрирует, что ZooKeeper может уже исключить процесс из лидерства, но не способен отменить внешнюю запись, сделанную после длительной паузы.

При FENCING=1 получатель сравнил переданную эпоху с активной в одной SQLite-транзакции вместе с обновлением указателя. После захвата лидерства B активной стала эпоха B. Возобновившийся A получил BadVersionError; указатель остался на единственной принятой версии 1.

Наблюдаемые строки журналов

```
2026-10-27T21:55:59.703+00:00 ENSEMBLE_INITIAL roles=['follower', 'leader', 'follower']

2026-10-27T21:56:01.651+00:00 ONE_SERVER_DOWN remaining_modes=['leader', 'follower'] write_ok=True

2026-10-27T21:56:07.566+00:00 TWO_SERVERS_DOWN last_mode=unknown client_operation=unavailable
error=KazooTimeoutError

2026-10-27T21:56:08.562+00:00 EPHEMERAL_AFTER_SESSION_CLOSE exists=False

2026-10-27T21:56:23.093+00:00 UNFENCED FAILOVER_SECONDS=10.413
backup_event=2026-10-27T21:56:22.909+00:00 coord-B BECAME_LEADER epoch=4
path=/coordinators/coord-B-0000000003

2026-10-27T21:57:01.838+00:00 UNFENCED FINAL pointer_version=2 active_epoch=4 result_matches_hw3=True
pair_keys=1008 occurrences=2382

2026-10-27T21:57:16.906+00:00 FENCED FAILOVER_SECONDS=10.938 backup_event=2026-10-27T21:57:16.901+00:00
coord-B BECAME_LEADER epoch=6 path=/coordinators/coord-B-0000000005

2026-10-27T21:57:46.238+00:00 FENCED FINAL pointer_version=1 active_epoch=6 result_matches_hw3=True
pair_keys=1008 occurrences=2382
```

4. Выводы

Почему три сервера, а не два или четыре?

ZooKeeper подтверждает запись большинством. При двух серверах отказ одного оставляет только половину ансамбля: большинство недоступно. Три сервера сохраняют два голоса после одного отказа. Четыре также переживают один отказ, но не два: оставшиеся два голоса не составляют большинства. Поэтому три узла — минимальный нечётный размер, который переживает отказ одного узла.

Почему эпоху проверяет получатель записи, а не ZooKeeper?

ZooKeeper управляет членством координаторов и выдаёт им эпохи, но расчёт записывает результат в отдельное хранилище. Оно не участвует в протоколе ZooKeeper. После паузы старый процесс может продолжить исполняться и отправить старый результат, хотя его сессия уже истекла. Получатель должен атомарно сравнить эпоху с текущей и отклонить устаревшую запись. Проверка только в координаторе не защищает от процесса, который проснулся после долгой паузы.

Ограничение демонстрации

Получатель результата представлен SQLite-файлом на общей машине. Это позволяет проверить атомарное сравнение эпохи и версии указателя. В распределённой системе та же проверка должна выполняться в фактическом получателе результата — например, транзакцией в целевой БД или условной записью в хранилище.

Файлы доказательств

Конфигурации серверов находятся в config/, команды управления — в scripts/, журналы ZooKeeper и координаторов — в logs/, итоговые указатели и сводка — в results/. Полный эталон пар ДЗ № 3 приложен в data/hw3_pair_counts.json.